

SNN-MNIST

基于pytorch, spikingjelly实现SNN训练MNIST手写数据集
两个实现方式:

- 单层全连接SNN网络
 - 最高测试准确率: 92.89%
 - 最高训练准确率: 93.48%
- 卷积SNN网络 (CSNN)
 - 最大测试准确率: 99.33%
 - 最大训练准确率: 99.99%

SNN-MNIST

1. 单层全连接SNN网络训练MNIST数据集

1.1 引言

1.2 实验方法

1.2.1 网络结构

1.2.2 数据准备

1.2.3 参数设置及优化器

1.2.4 训练过程

1.2.5 结果可视化

1.3 反向传播更新规则分析

1.4 结论

2. 卷积SNN网络 (CSNN) 训练MNIST数据集

2.1 引言

2.2 模型结构

2.3 训练

2.3.1 训练过程

2.4 反向传播更新规则

2.5 梯度替代原理

2.5 结论

参考

1. 单层全连接SNN网络训练MNIST数据集

1.1 引言

本文使用单层全连接脉冲神经网络 (Spiking Neural Network, SNN) 对MNIST数据集进行分类MNIST数据集包含手写数字的图像, 是机器学习和神经网络领域中的一个经典测试数据集。

1.2 实验方法

1.2.1 网络结构

SNN模型定义如下:

```

1 class SNN(nn.Module):
2     def __init__(self, tau):
3         super().__init__()
4
5         self.layer = nn.Sequential(
6             layer.Flatten(),
7             layer.Linear(28 * 28, 10, bias=False),
8             neuron.LIFNode(tau=tau, surrogate_function=surrogate.ATan()),
9         )
10
11     def forward(self, x: torch.Tensor):
12         return self.layer(x)

```

该模型包含一个线性层和一个LIF神经元层。LIF（Leaky Integrate-and-Fire）神经元具有泄露整合和放电机制，通过 τ (tau) 参数控制其时间常数。

1.2.2 数据准备

使用PyTorch和TorchVision加载MNIST数据集，并进行数据预处理：

```

1 data_dir = './data'
2 batch_size = 128
3 num_workers = 1
4 train_dataset = torchvision.datasets.MNIST(
5     root=data_dir,
6     train=True,
7     transform=torchvision.transforms.ToTensor(),
8     download=True
9 )
10
11 test_dataset = torchvision.datasets.MNIST(
12     root=data_dir,
13     train=False,
14     transform=torchvision.transforms.ToTensor(),
15     download=True
16 )
17
18 train_data_loader = data.DataLoader(
19     dataset=train_dataset,
20     batch_size=batch_size,
21     shuffle=True,
22     drop_last=True,
23     num_workers=num_workers,
24     pin_memory=True
25 )
26
27 test_data_loader = data.DataLoader(
28     dataset=test_dataset,
29     batch_size=batch_size,
30     shuffle=False,
31     drop_last=False,
32     num_workers=num_workers,

```

```
32     pin_memory=True
33 )
```

1.2.3 参数设置及优化器

实验参数设置如下：

```
1  tau = 2.0
2  T = 100
3  epochs = 100
4  learning_rate = 0.001
5  device = torch.device("cuda:0" if torch.cuda.is_available() else "cpu")
6
7  net = SNN(tau=tau)
8  net.to(device)
9
10 # 使用adam优化器
11 optimizer = torch.optim.Adam(net.parameters(), lr=learning_rate)
12 # 使用泊松编码器
13 encoder = encoding.PoissonEncoder()
```

1.2.4 训练过程

训练过程中，使用均方误差（MSE）作为损失函数，并在每个epoch结束后记录训练和测试的准确率与损失：

```
1  train_loss_record = []
2  train_acc_record = []
3  test_loss_record = []
4  test_acc_record = []
5
6  for epoch in range(epochs):
7      net.train()
8      train_loss = 0
9      train_acc = 0
10     train_samples = 0
11
12     for img, label in train_data_loader:
13         optimizer.zero_grad()
14         img, label = img.to(device), label.to(device)
15         label_onehot = F.one_hot(label, 10).float()
16         out_fr = 0.
17         for t in range(T):
18             encoded_img = encoder(img)
19             out_fr += net(encoded_img)
20         out_fr = out_fr / T
21         loss = F.mse_loss(out_fr, label_onehot)
22         loss.backward()
23         optimizer.step()
24         train_samples += label.numel()
25         train_loss += loss.item() * label.numel()
```

```

26         train_acc += (out_fr.argmax(1) == label).float().sum().item()
27         functional.reset_net(net)
28
29     train_loss /= train_samples
30     train_acc /= train_samples
31
32     train_loss_record.append(train_loss)
33     train_acc_record.append(train_acc)
34
35     # 测试过程省略，类似训练过程
36     # 记录test_loss和test_acc
37
38     print(f'Epoch {epoch + 1}/{epochs}, Train Loss: {train_loss:.4f}, Train Acc:
{train_acc:.4f}')

```



1.2.5 结果可视化


训练和测试结果使用Matplotlib进行可视化展示：

```

1  # 测试集准确率变化图像
2  plt.figure()
3  plt.plot(test_acc_record)
4  plt.xlabel('Epoch')
5  plt.ylabel('Test Accuracy')
6  plt.title('Test Accuracy')
7  plt.show()
8
9  # 训练集损失变化图像
10 fig = plt.figure()
11 ax = fig.add_subplot(2,1, 1)
12 ax.plot(train_loss_record)
13 ax.set_title(f'Train Loss')
14 ax = fig.add_subplot(2,1, 2)
15 ax.plot(test_loss_record)
16 ax.set_title(f'Test Loss')
17 plt.show()

```





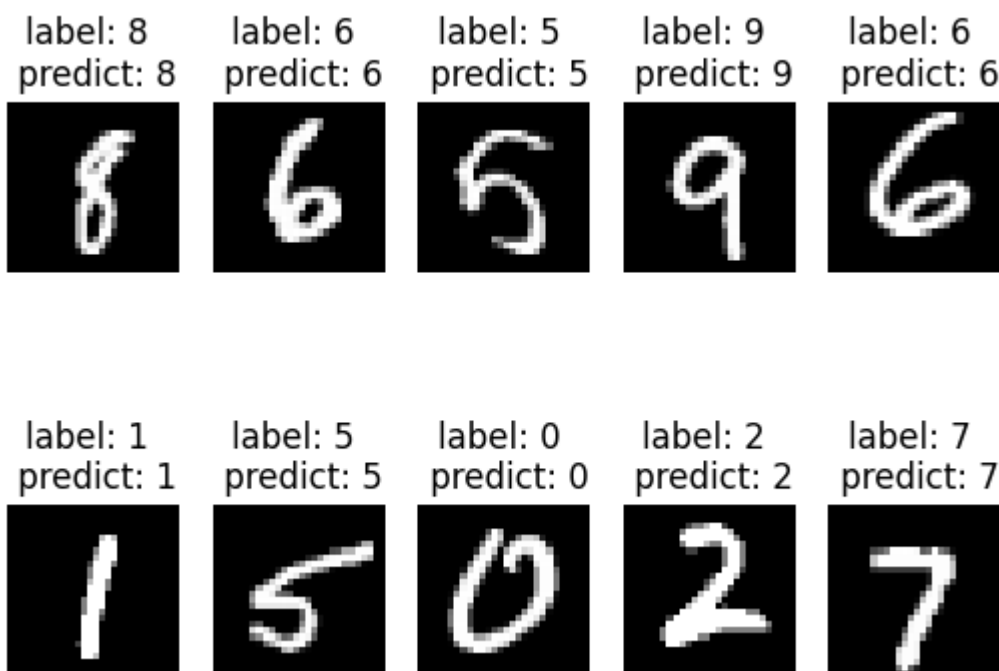
1.3 反向传播更新规则分析

在脉冲神经网络中，反向传播的主要挑战在于处理非连续的脉冲事件。通过引入代理梯度（surrogate gradient）方法，可以近似计算不可导点的梯度。具体来说，LIF神经元的导数被代理函数（如Arctan函数）近似，从而使得误差可以通过网络传播。

1.4 结论

100个epochs中最高训练准确率达93.48%，测试集最高准确率92.89%

任选10张测试集数据，预测结果：



从训练结果可以看出，随着训练的进行，训练损失逐渐减小，准确率逐渐提高。实验成功验证了单层全连接SNN在MNIST数据集上的有效性。本文通过单层全连接SNN模型成功实现了对MNIST数据集的分类，验证了SNN的有效性。使用代理梯度方法解决了脉冲神经网络中反向传播的挑战。未来的研究可以尝试更复杂的网络结构和优化算法，以进一步提高性能。

2. 卷积SNN网络（CSNN）训练MNIST数据集

2.1 引言

本实验报告介绍了使用卷积脉冲神经网络(CSNN)对MNIST数据集进行分类训练的过程。该模型结合了卷积神经网络(CNN)的特征提取能力和脉冲神经网络(SNN)的时间动态特性。重点描述了模型结构设计和SNN的反向传播更新规则。

2.2 模型结构

{Conv2d-BatchNorm2d-IFNode-MaxPool2d}-{Conv2d-BatchNorm2d-IFNode-MaxPool2d}-{Linear-IFNode}

本实验中的CSNN模型由多个卷积层、池化层和全连接层组成，具体结构如下：

```
1 CSNN(  
2     (conv_fc): Sequential(  
3         (0): Conv2d(1, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), bias=False,  
4             step_mode=m)  
5         (1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True,  
6             track_running_stats=True, step_mode=m)  
7         (2): IFNode(  
8             v_threshold=1.0, v_reset=0.0, detach_reset=False, step_mode=m, backend=torch  
9             (surrogate_function): ATan(alpha=2.0, spiking=True)  
10    )  
11 )
```

```

9      (3): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False,
step_mode=m)
10     (4): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1), bias=False,
step_mode=m)
11     (5): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True, step_mode=m)
12     (6): IFNode(
13         v_threshold=1.0, v_reset=0.0, detach_reset=False, step_mode=m, backend=torch
14         (surrogate_function): ATan(alpha=2.0, spiking=True)
15     )
16     (7): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False,
step_mode=m)
17     (8): Flatten(start_dim=1, end_dim=-1, step_mode=m)
18     (9): Linear(in_features=3136, out_features=1024, bias=False)
19     (10): IFNode(
20         v_threshold=1.0, v_reset=0.0, detach_reset=False, step_mode=m, backend=torch
21         (surrogate_function): ATan(alpha=2.0, spiking=True)
22     )
23     (11): Linear(in_features=1024, out_features=10, bias=False)
24     (12): IFNode(
25         v_threshold=1.0, v_reset=0.0, detach_reset=False, step_mode=m, backend=torch
26         (surrogate_function): ATan(alpha=2.0, spiking=True)
27     )
28 )
29 )

```

模型定义代码如下：

```

1  class CSNN(nn.Module):
2      def __init__(self, T: int, channels: int):
3          super().__init__()
4          #T 为模拟时间步数
5          self.T = T
6
7          self.conv_fc = nn.Sequential(
8              layer.Conv2d(1, channels, kernel_size=3, padding=1, bias=False),
9              layer.BatchNorm2d(channels),
10             neuron.IFNode(surrogate_function=surrogate.ATan()),
11             layer.MaxPool2d(2, 2), # 14 * 14
12
13             layer.Conv2d(channels, channels, kernel_size=3, padding=1, bias=False),
14             layer.BatchNorm2d(channels),
15             neuron.IFNode(surrogate_function=surrogate.ATan()),
16             layer.MaxPool2d(2, 2), # 7 * 7
17
18             layer.Flatten(),
19             layer.Linear(channels * 7 * 7, channels * 4 * 4, bias=False),
20             neuron.IFNode(surrogate_function=surrogate.ATan()),
21

```



```

22         layer.Linear(channels * 4 * 4, 10, bias=False),
23         neuron.IFNode(surrogate_function=surrogate.ATan()),
24     )
25
26     #为了更快的训练速度，我们将网络设置成多步模式
27     functional.set_step_mode(self, step_mode='m')
28
29     #脉冲编码器：返回卷积神经网络的前三层：卷积层、批归一化层和脉冲发放神经元层
30     def spiking_encoder(self):
31         return self.conv_fc[0:3]

```

将图片直接输入到SNN，而不是编码后在输入，是近年来深度SNN的常见做法，在此也使用这样的方法。在这种情况下，实际的 图片-脉冲 编码是由网络中的前三层，也就是 {Conv2d-BatchNorm2d-IFNode} 完成。

网络的输入直接是 `shape=[N, C, H, W]` 的图片，我们将其添加时间维度，并复制 `T` 次，得到 `shape=[T, N, C, H, W]` 的序列，然后送入到网络层。网络的输出定义为最后一层脉冲神经元的脉冲发放频率。因而，网络的前向传播定义为：

```

1 class CSNN(nn.Module):
2     def forward(self, x: torch.Tensor):
3         # x.shape = [N, C, H, W]
4         x_seq = x.unsqueeze(0).repeat(self.T, 1, 1, 1, 1) # [N, C, H, W] -> [T, N, C, H,
5         W]
6         x_seq = self.conv_fc(x_seq)
7         fr = x_seq.mean(0)
8         return fr

```

2.3 训练

使用SGD优化器

```

1 lr = 0.1
2 optimizer = torch.optim.SGD(net.parameters(), lr, momentum=0.9)

```

2.3.1 训练过程

为了训练SNN，采用了替代梯度法对IF神经元进行优化。训练代码如下：

```

1 epochs = 64
2 train_acc_record = []
3 train_loss_record = []
4 test_acc_record = []
5 test_loss_record = []
6
7 for epoch in range(epochs):
8     start_time = time.time()

```

```

9     net.train()
10    train_loss = 0
11    train_acc = 0
12    train_samples = 0
13    for img, label in train_data_loader:
14        optimizer.zero_grad()
15        img = img.to(device)
16        label = label.to(device)
17        label_onehot = F.one_hot(label, 10).float()
18
19
20        out_fr = net(img)
21        loss = F.mse_loss(out_fr, label_onehot)
22        loss.backward()
23        optimizer.step()
24
25        train_samples += label.numel()
26        train_loss += loss.item() * label.numel()
27        train_acc += (out_fr.argmax(1) == label).float().sum().item()
28
29    functional.reset_net(net)
30
31    train_time = time.time()
32    train_speed = train_samples / (train_time - start_time)
33    train_loss /= train_samples
34    train_acc /= train_samples
35    train_acc_record.append(train_acc)
36    train_loss_record.append(train_loss)
37
38    net.eval()
39    test_loss = 0
40    test_acc = 0
41    test_samples = 0
42    with torch.no_grad():
43        for img, label in test_data_loader:
44            img = img.to(device)
45            label = label.to(device)
46            label_onehot = F.one_hot(label, 10).float()
47            out_fr = net(img)
48            loss = F.mse_loss(out_fr, label_onehot)
49
50            test_samples += label.numel()
51            test_loss += loss.item() * label.numel()
52            test_acc += (out_fr.argmax(1) == label).float().sum().item()
53            functional.reset_net(net)
54    test_time = time.time()
55    test_speed = test_samples / (test_time - train_time)
56    test_loss /= test_samples
57    test_acc /= test_samples
58    test_acc_record.append(test_acc)
59    test_loss_record.append(test_loss)

```

```

60
61
62     print(f'epoch = {epoch}, train_loss ={train_loss: .4f}, train_acc ={train_acc:
        .4f}, test_loss ={test_loss: .4f}, test_acc ={test_acc: .4f}')
63     print(f'train speed ={train_speed: .4f} images/s, test speed ={test_speed: .4f}
        images/s')
64     print(f'escape time: ' , time.strftime('%Y-%m-%d
        %H:%M:%S',time.localtime(time.time()))))
65
66

```

2.4 反向传播更新规则

在SNN中，由于脉冲神经元的不连续性，传统的反向传播算法不能直接应用。因此，使用替代梯度方法对脉冲神经元进行优化。具体步骤如下：

1. **正向传播**：通过网络计算输入样本的输出脉冲频率。
2. **损失计算**：使用交叉熵损失函数计算预测结果与真实标签之间的误差。
3. **替代梯度**：由于脉冲神经元的非连续性，使用替代函数（如Arctan函数）计算近似梯度。
4. **参数更新**：通过反向传播算法，根据计算得到的替代梯度信息更新网络权重。

在代码中，IF神经元的替代函数使用了Arctan函数，如下所示：

```

1 | neuron.IFNode(surrogate_function=surrogate.ATan())

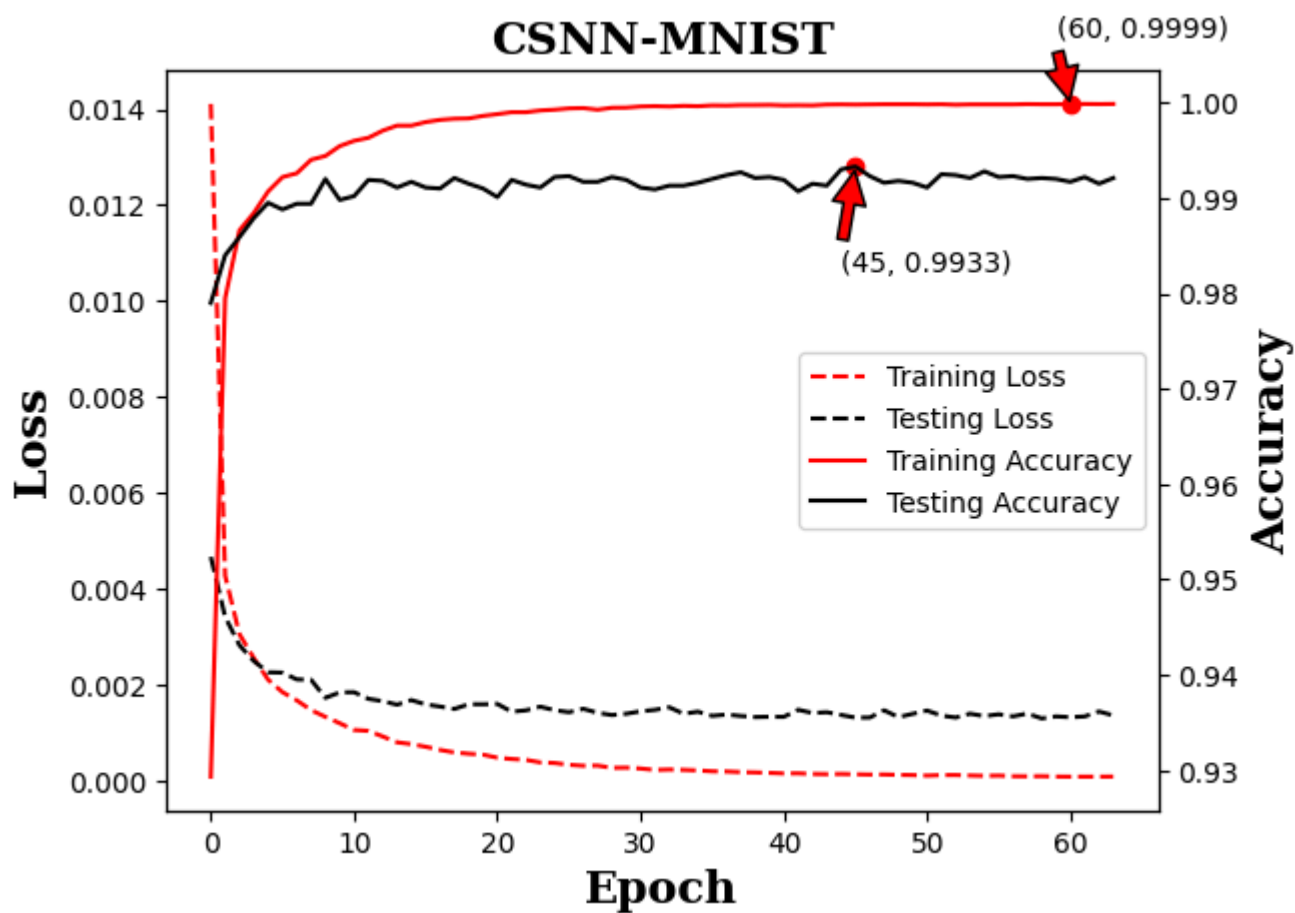
```

2.5 梯度替代原理

[梯度替代 — spikingjelly alpha 文档](#)

2.5 结论

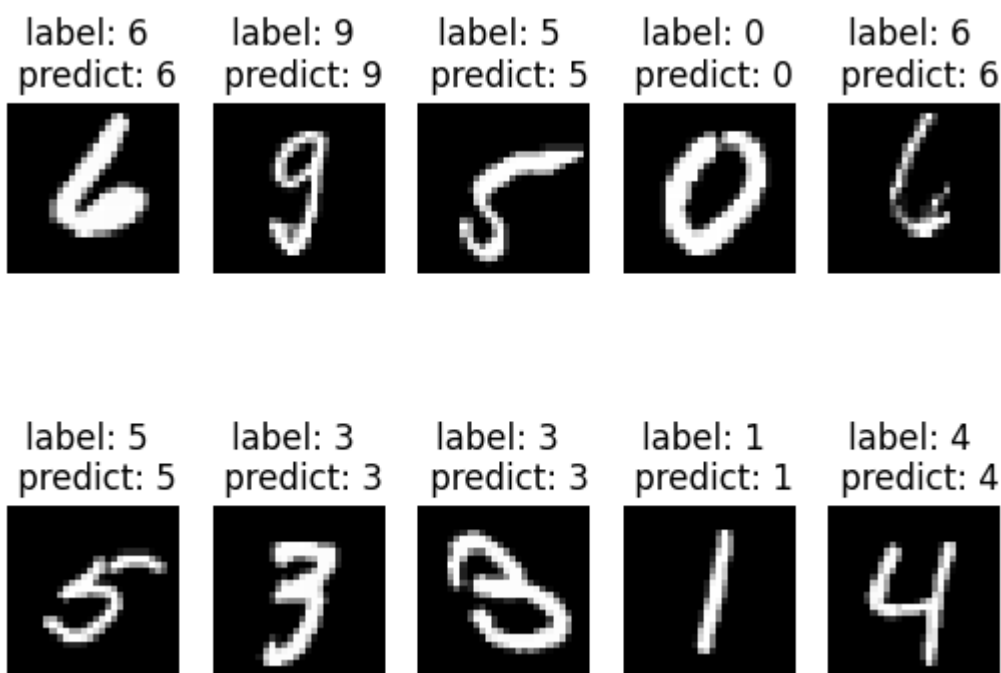
训练结果：



最大测试准确率: 99.33%

最大训练准确率: 99.99%

随机10张测试集识别:



本实验展示了如何使用CSNN对MNIST数据集进行分类，详细介绍了模型结构。通过替代梯度方法，成功实现了脉冲神经网络的训练，并验证了其在图像分类任务中的有效性。实验结果表明，CSNN在处理时间序列数据时具有良好的性能，能够有效捕捉图像中的特征信息。

CSNN比单层全连接SNN有着更好的性能

参考

- MNIST数据集介绍: <http://yann.lecun.com/exdb/mnist/>
- [使用单层全连接SNN识别MNIST — spikingjelly alpha 文档](#)
- [使用卷积SNN识别Fashion-MNIST — spikingjelly alpha 文档](#)